

基于深度学习的脑机接口机械臂闭环控制系统

BCI Control System Project

2026 年 4 月 25 日

1. 目前还有什么问题没有解决

当前仍未解决的核心问题

传统 MI-BCI 机械臂控制距离真实落地还有明显差距，主要体现在：

- **信号非平稳**：不同用户、不同会话之间 EEG 差异很大
- **开环控制脆弱**：单次分类错误会直接带偏机械臂动作
- **硬件部署困难**：实验室常用 64 通道，实际更需要 8 通道设备

项目目标

构建一个闭环控制系统，把有噪声的运动想象 EEG 转化为稳定的机械臂控制动作，并保留面向 OpenBCI 的部署可能性。

和机器人岗位的关系

这个项目本质上不是单纯做 EEG 分类，而是在做感知有噪声时的决策与控制鲁棒性，这和机器人决策算法的核心问题高度一致。

2. 其他人做了什么，我做了什么，我的更好在哪里

已有工作

- 大多数方法重点放在 **离线 EEG 分类**
- 常见方法包括 CSP、EEGNet、CNN、Transformer
- 很多工作默认 **分类结果直接映射成动作**
- 高精度结果通常依赖 **64 通道实验室设备**

我的工作

- 设计 EEGTransformer 做分类
- 用迁移学习解决跨被试泛化
- 用 Transformer DQN 做 **闭环控制纠错**
- 做 8 通道压缩和 OpenBCI 部署设计


我的改进

- 不再停留在分类，而是构建 **感知-决策-执行闭环**
- 不要求分类绝对正确，也能保持稳定控制
- 同时考虑 **精度、鲁棒性、部署可行性**
- 在 82.22% 分类精度下仍实现 99% 控制成功率

一句话概括

其他方法更多是在回答“能不能分对类别”，我的工作更进一步回答了“在分类不完美的情况下，系统能不能仍然稳定完成控制任务”。

3. 系统整体架构



从 EEG 预处理、EEGTransformer 分类，到闭环 DQN 控制与机械臂执行，构成完整系统链路

4. EEGTransformer 与迁移学习

分类器设计

- **CNN 前端**: 提取运动皮层相关空间模式
- **Transformer 编码器**: 建模 4 秒 EEG 序列的长时依赖
- **迁移学习**: 先跨被试预训练, 再做个体微调

设计动机

CNN 提供 EEG 所需的空域归纳偏置, Transformer 提供更强的时序建模能力, 两者结合比单一范式更适合这个任务。

关键结果

- BCI IV-2a (22 通道, 4 分类): **73.80%**
- BCI IV-2b (3 通道, 2 分类): **82.87%**
- PhysioNet 跨被试训练: **56.54%**
- PhysioNet 微调后: **88.78%**

核心结论

个体微调弥补了 **32 个百分点** 的性能差距, 说明预训练模型学到的是可迁移的运动想象表征, 而不是只记住了单个被试的数据分布。

5. 关键量化结果（来自 Final Report）

PhysioNet 分类结果

训练方式	精度 (%)	备注
跨被试训练	56.54	109 人 pooled
个体微调	88.78	10 人, 5-fold CV

含义

这说明预训练模型具备可迁移表征，经过少量个体校准后可以显著提升性能。


DQN 架构对比

架构	时间 (s)	到达率	Reward
CNN+LSTM	111.7	97%	8.79
Light Trans.	134.0	99%	10.07
Transformer DQN	177.8	100%	10.39

含义

Transformer DQN 在最终控制表现上最好，证明时序建模对闭环决策是有效的。

6. 迁移学习效果



意义

对真实系统来说，这意味着新用户不需要从零训练模型，只需要较少的校准数据，就可以快速得到较高的个体化分类性能。


7. 8 通道部署与预处理取舍

通道压缩策略

- 通过 leave-one-channel-out 消融评估各电极重要性
- 结果表明 **C3** 是最关键通道
- 构造 OpenBCI 兼容的 8 通道集合：
- C3, C4, FC3, FC4, CP3, CP4, Cz, FCz

预处理取舍

- 8–30 Hz 带通滤波平均提升：+18.44%
- ICA 额外增益只有：+1.51%
- 最终主流程保留 **bandpass-only**



部署结果

即使降到 8 通道，经过个体微调后平均精度仍达到 72.54%，说明该方案在消费级硬件上仍具有可用性。


8. 闭环决策层：Transformer DQN

MDP 建模

- 状态：末端位置、目标位置、距离
- 可选增强状态：EEG 预测类别 + 置信度
- 动作：左 / 右 / 上 / 下
- 奖励：到达目标奖励、距离改善奖励、步数惩罚、震荡和越界惩罚

关键思想


分类器只提供有噪声的方向线索，真正的动作选择由闭环决策模块完成，它会在连续状态下学习如何纠错。



结构对比

- CNN+LSTM: 97% reach rate
- Light Transformer: 99%
- **Transformer DQN: 100%**

9. 端到端结果：分类有噪声，控制仍然稳定



报告中的原始结果表

Agent State	维度	到达率	Reward	时间 (s)
Arm only	5	99.0%	8.71	1130
Arm + EEG	7	98.7%	8.59	668

分类精度： 82.22%

核心结论

闭环强化学习能够吸收分类误差，而不是机械执行分类结果。这说明该系统更像一个鲁棒决策系统，而不是简单的“分类即动作”映射器。

10. 工程实现范围与验证边界

我实际完成的部分

- MNE / PyTorch 的预处理、训练、微调和评估
- PyBullet 仿真环境与强化学习训练
- BrainFlow 接入 OpenBCI 实时 EEG 流
- SO-101 机械臂串口控制链路

当前验证边界

- 完整软件链路已实现
- 端到端仿真验证已完成
- OpenBCI 流接口已实现
- SO-101 控制接口已实现
- 由于伦理审批限制，尚未进行真人在线闭环实验

面试时的表述方式

这项工作应当被表述为仿真已验证、面向部署的系统，而不是已经完成真人实测的最终产品。

11. 如何映射到机器人决策算法岗位

岗位关注点	我的项目对应证据
不确定感知下的决策	DQN 在 EEG 噪声下持续纠错并完成目标到达
仿真到部署	先在 PyBullet 验证, 再对接 OpenBCI 与 SO-101 接口
算法工程能力	EEGTransformer、微调流程、RL 环境与评估脚本均由我实现
系统联调能力	数据处理、分类、控制、通信链路完整打通
工程取舍能力	通道压缩、预处理消融、部署成本与性能平衡

一句话总结

这个项目最适合被概括为：一个在不完美感知条件下仍能稳定完成控制任务的闭环决策系统。